

# THEORIE DES LANGAGES ET AUTOMATES

# INTRODUCTION

- Les automates ont été définis dans les années 40-50.
- Ils sont utilisés dans les beaucoup de domaines comme:
  - Compilation des langages
  - Reconnaissance de texte
  - Conception de protocoles
  - Synthèse de programmes
  - Vérification de programmes
- Fin des années 50, Chomsky un linguiste a commencé l'étude des grammaires formelles.
- Les liens entre les grammaires et les automates ont été étudiés par la suite

- Alan Turing a étudié en 1930, avant que n'existe le premier ordinateur, une question fondamentale en Informatique:

Existe-t-il une limite à ce qu'on peut calculer?

Sa réponse:

oui, il y a des problèmes qu'on ne peut pas résoudre à l'aide d'un ordinateur même si on suppose une mémoire non bornée

- Bibliographie
  - P. Dehornoy, "Mathématiques d l'Informatique", Dunod, 2000.
  - J. Hopcroft et J. Ullmann, "Introduction to automata theory, Languages and Computations", Addison-Wesley, 1979.
- Webographie
  - <http://njussien.e-constraints.net/lla/>
  - <http://brassens.upmf-grenoble.fr/~alecomte/>

# Plan

- Mots et langages
- Automates à états finis
- Langages réguliers
- Grammaires
- Langages hors contextes et automates à pile
- Machine de Turing

# Mots et langages

# Mots

- Un **alphabet**  $\Sigma$  est un ensemble fini non vide de lettres (ou symboles)
- Un **mot** est une suite finie de symboles de l'alphabet  $\Sigma$   
Exemple: 001110 est un mot sur  $\Sigma = \{0, 1\}$
- Un mot  $w$  constitué de  $m$  symboles est dit de longueur  $m$ . On note  $|w| = m$ .

Exemple:  $|001110| = 6$   
 $|\varepsilon| = 0$

- On note  $\Sigma^*$  l'ensemble des mots sur  $\Sigma$
- $\Sigma^i$  est l'ensemble des mots de longueur  $i$  .  
On a :  $\Sigma^* = \bigcup_n \Sigma^n$
- NB : On note  $\Sigma^+$  l'ensemble  $\Sigma^* \setminus \{\varepsilon\}$



# Opérations

- **Concaténation**

Soit  $x \in \Sigma^*$  et  $y \in \Sigma^*$  tels que  $|x| = m$  et  $|y| = n$ .

La concaténation de  $x$  et  $y$  notée  $xy$  est le mot de longueur  $m + n$  dont les  $m$  premiers symboles sont ceux de  $x$  et les  $n$  derniers ceux de  $y$

- Propriétés de la concaténation

- associativité
- non commutativité
- $\varepsilon$  neutre pour la concaténation

- Portions de mots:

Soient  $w, x, y, z$  quatre mots tels que :  $w = xyz$

- $x$  est un **préfixe** de  $w$
- $y$  est une **sous-chaîne** de  $w$
- $z$  est un **suffixe** de  $w$

- Exemple

Si le mot considéré est  $w = 00110$

- préfixes :  $\varepsilon, 0, 00, 001, 0011$  et  $w$
- suffixes :  $\varepsilon, 0, 10, 110, 0110$  et  $w$
- sous-chaînes :  $\varepsilon, 0, 1, 00, 01, 10, 11, 001, 011, 110, 0011, 0110$  et  $w$

- L'opération **miroir** est définie de la manière suivante :
  - si  $|w| = 0$ , alors  $w = \varepsilon$  et  $w^R = \varepsilon$
  - Sinon  $|w| > 0$ ,  $w = au$  ( $a \in \Sigma$  et  $u \in \Sigma^*$ ),  $w^R = u^R a$ .

Si  $w$  est tel que  $w^R = w$  alors  $w$  est un **palindrome**.

# Langages

- **Langage**

Un langage (formel)  $L$  sur un alphabet  $\Sigma$  est un sous-ensemble quelconque de  $\Sigma^*$  tel que  $L \subseteq \Sigma^*$

- Exemple

Le langage des nombres est défini sur un alphabet  $\Sigma = \{0, 1, \dots, 9\}$ . 02, 00310, 3200 sont alors des mots sur  $\Sigma$ . On définira le langage des nombres comme les mots sur  $\Sigma$  qui ne commencent pas par 0. Ainsi, 1233 et 3200 seront des mots du langage mais pas 00310.

- **Concaténation de langages**

Soient  $L1$  et  $L2$  deux langages, leur concaténation est le langage

$$L1L2 = \{xy | x \in L1, y \in L2\}$$

- Propriétés de la concaténation
  - associative
  - non commutative
  - $\{\varepsilon\}$  neutre
  - $\emptyset$  absorbant

- **Clôture de Kleene**

- $L^2 = LL$  la concaténation de  $L$  avec lui-même
- $L^0 = \{\varepsilon\}$
- clôture de Kleene

$$L^* = \bigcup_{i=0 \rightarrow \infty} L^i$$

- Autres opérations sur les langages:
  - $A + B$  (ou  $A \cup B$ ) =  $\{w \in X^* \mid w \in A \text{ ou } w \in B\}$
  - $A \cap B = \{w \in X^* \mid w \in A \text{ et } w \in B\}$
  - $A - B$  (ou  $A \setminus B$ ) =  $\{w \in X^* \mid w \in A \text{ et } w \notin B\}$
  - $L^R = \{u^R \mid u \in L\}$  (image miroir d'un langage)

- Propriétés:

- $A \emptyset = \emptyset A = \emptyset$

- $A \{\varepsilon\} = \{\varepsilon\} A = A$

- $A \subseteq B \Rightarrow AC \subseteq BC$

- $A^* = \bigcup_{i=0 \rightarrow \infty} A^i$

- $A^+ = \bigcup_{i=1 \rightarrow \infty} A^i$

- Remarque:

On n'a pas la distributivité de la concaténation par rapport à l'intersection



## **Théorème d'Arden**

A, B langages sur  $\Sigma$ .

Si  $\varepsilon \notin A$  alors l'équation  $L = AL + B$  admet une unique solution  $L = A^*B$